


# Linear Algebra Practice Day 3

2025.07.14



# 0. 환경설정

# Google Colab

## Colab이란?

Colaboratory(줄여서 'Colab'이라고 함)을 통해 브라우저 내에서 Python 스크립트를 작성하고 실행할 수 있습니다.

- 구성이 필요하지 않음
- 무료로 GPU 사용
- 간편한 공유

학생이든, 데이터 과학자든, AI 연구원이든 Colab으로 업무를 더욱 간편하게 처리할 수 있습니다. [Colab 소개 영상](#) 또는 [Colab에서 놓치기 쉬운 기능을 시청](#)하여 자세한 내용을 확인하거나 아래에서 바로 시작해 보세요.

Link: <https://colab.research.google.com/>

# Google Colab

Open notebook

Examples >

Recent >

Google Drive >

**GitHub >**

Upload >

Enter a GitHub URL or search by organization or user

https://github.com/jonggul2/linear-algebra-practice.git

Q

☐ Include private repos

Repository:

Branch:

jonggul2/linear-algebra-practice

main

Path

[linear\\_algebra\\_practice\\_day1.ipynb](#)

[linear\\_algebra\\_practice\\_day2.ipynb](#)

[linear\\_algebra\\_practice\\_day3.ipynb](#)

+ New notebook

Cancel

# Google Colab

Open notebook

Examples >

Recent >

Google Drive >

GitHub >

Upload >

Enter a GitHub URL or search by organization or user

https://github.com/jonggul2/linear-algebra-practice.git

🔍

☐ Include private repos

Repository: [🔗](#)

Branch: [🔗](#)

jonggul2/linear-algebra-practice ▾

main ▾

Path

🔗 linear\_algebra\_practice\_day1.ipynb 🔍 📄

🔗 linear\_algebra\_practice\_day2.ipynb 🔍 📄


🔗 linear\_algebra\_practice\_day3.ipynb 🔍 📄

+ New notebook

Cancel

Github Link: <https://github.com/jonggul2/linear-algebra-practice.git>

# Google Colab

 linear\_algebra\_practice\_day1.ipynb

File Edit View Insert Runtime Tools Help

Q Commands + Code + Text ▶ Run all Copy to Drive

Connect Gemini J

↑ ↓ 🔗 ✎ 📄 🗑️ ⋮

⋮  
📁  
<>  
🔍  
📁

▼ Linear Algebra and Machine Learning Practice (Day 1)

목차 (Table of Contents)

준비 과정

- 라이브러리 설치 및 불러오기
- MNIST 데이터셋 불러오기

실습 (Practice)

- 벡터 생성과 기본 속성
- 벡터의 기본 연산
- 벡터의 선형 결합과 내적
- 벡터의 크기와 거리
- 행렬 생성 및 속성
- 행렬의 기본 연산
- K-means 기본 원리
- K-means 적용: MNIST 중심 시각화

▼ 준비하기: 라이브러리 설치 및 불러오기

```
[ ] # 라이브러리 설치
import subprocess
import sys

def install_if_not_exists(package):
    try:
        import_(package)
    except ImportError:
        subprocess.check_call([sys.executable, "-m", "pip", "install", package])

# 모든 실습에 필요한 라이브러리 목록
required_packages = ["numpy", "matplotlib", "scikit-learn"]
```

📄 Variables



# Google Colab

The screenshot shows the Google Colab interface. At the top, the file name is 'linear\_algebra\_practice\_day1.ipynb'. The 'File' menu is open, and 'Save a copy in Drive' is highlighted with a red box. Other menu options include 'View on GitHub', 'New notebook in Drive', 'Open notebook' (with a 'Ctrl+O' shortcut), 'Upload notebook', 'Rename', 'Save a copy as a GitHub Gist', 'Save' (with a 'Ctrl+S' shortcut), 'Revision history', 'Download', and 'Print' (with a 'Ctrl+P' shortcut). The main workspace area contains the text 'Linear Algebra Learning Practice (Day 1)'. On the right side of the workspace, there are icons for undo, redo, copy, paste, and delete. Below the workspace, there is a list of links: '5. 행렬 생성 및 속성', '6. 행렬의 기본 연산', '7. K-means 기본 원리', and '8. K-means 적용: MNIST 중심 시각화'.

## ✓ 준비하기: 라이브러리 설치 및 불러오기

```
[ ] # 라이브러리 설치
import subprocess
import sys

def install_if_not_exists(package):
    try:
        __import__(package)
    except ImportError:
        subprocess.check_call([sys.executable, "-m", "pip", "install", package])

# 모든 실습에 필요한 라이브러리 목록
required_packages = ["numpy", "matplotlib", "scikit-learn"]
```

Variables

# 목차

## ✓ Linear Algebra and Machine Learning Practice (Day 3)

### 목차 (Table of Contents)

#### 준비 과정

- [라이브러리 설치 및 불러오기](#)
- [MNIST 데이터셋 불러오기](#)

#### 실습 (Practice)

1. [Cholesky 분해 \(Cholesky Decomposition\)](#)
2. [고유값 분해 \(Eigendecomposition\)](#)
3. [특이값 분해 \(Singular Value Decomposition, SVD\)](#)
4. [주성분 분석 \(Principal Component Analysis, PCA\)](#)



# 준비하기

## ▽ 준비하기: 라이브러리 설치 및 불러오기

✓  
11s

```
[1] # 라이브러리 설치
import subprocess
import sys

def install_if_not_exists(package):
    try:
        __import__(package)
    except ImportError:
        subprocess.check_call([sys.executable, "-m", "pip", "install", package])

# 모든 실습에 필요한 라이브러리 목록
required_packages = ["numpy", "matplotlib", "scipy", "scikit-learn"]
for package in required_packages:
    install_if_not_exists(package)

# 라이브러리 불러오기
import numpy as np
import matplotlib.pyplot as plt
import scipy.linalg
from sklearn.datasets import fetch_openml

# 전체 실습의 재현성을 위해 랜덤 시드를 고정합니다.
np.random.seed(0)
```

# 준비하기

## ✓ MNIST 데이터셋 불러오기

scikit-learn의 `fetch_openml`을 사용하여 MNIST 손글씨 숫자 데이터셋을 불러옵니다. 데이터는 784개의 픽셀(28x28)로 구성된 이미지이며, 0~255 값을 갖습니다. 실습에서 사용할 수 있도록 255로 나누어 정규화합니다.

✓  
18s

```
[2] print("MNIST 데이터셋을 불러오는 중... (몇 분 정도 소요될 수 있습니다)")
    try:
        # as_frame=False : numpy array로 받기
        # parser='auto' : 최신 scikit-learn에서 권장하는 파서
        mnist = fetch_openml('mnist_784', version=1, as_frame=False, parser='auto')

        X_mnist_data = mnist.data / 255.0 # 정규화
        y_mnist_data = mnist.target.astype(int)

        print("MNIST 데이터셋 로드 완료.")
        print(f"데이터 형태: {X_mnist_data.shape}")
        print(f"레이블 형태: {y_mnist_data.shape}")
    except Exception as e:
        print(f"데이터셋 로드 중 오류 발생: {e}")
        print("인터넷 연결을 확인하거나, 잠시 후 다시 시도해주세요.")
        X_mnist_data, y_mnist_data = None, None
```



MNIST 데이터셋을 불러오는 중... (몇 분 정도 소요될 수 있습니다)  
MNIST 데이터셋 로드 완료.  
데이터 형태: (70000, 784)  
레이블 형태: (70000,)

# 1. Cholesky 분해 (Cholesky Decomposition)

# 1. Cholesky 분해 (Cholesky Decomposition)

## ✓ 1. Cholesky 분해 (Cholesky Decomposition)

Cholesky 분해는 행렬  $A$ 가 대칭(Symmetric)이면서 양의 정부호(Positive Definite)라는 특별한 조건을 만족할 때 사용할 수 있는 효율적인 행렬 분해 방법입니다.

행렬  $A$ 를 아래와 같이 하삼각행렬(Lower-triangular matrix)  $L$ 과 그 전치 행렬  $L^T$ 의 곱으로 분해합니다.

$$A = LL^T$$
$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} = \begin{bmatrix} l_{11} & 0 & \cdots & 0 \\ l_{21} & l_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \cdots & l_{nn} \end{bmatrix} \begin{bmatrix} l_{11} & l_{21} & \cdots & l_{n1} \\ 0 & l_{22} & \cdots & l_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & l_{nn} \end{bmatrix}$$

Cholesky 분해는 선형 시스템  $Ax=b$ 를 매우 효율적으로 푸는 데 사용됩니다.  $A$ 를  $LL^T$ 로 대체하면, 복잡한 문제가 다음과 같이 두 개의 간단한 삼각 시스템 문제로 나뉩니다.

$$\begin{aligned} Ax &= b \\ (LL^T)x &= b \\ L(L^Tx) &= b \end{aligned}$$

여기서  $L^Tx$ 를  $y$ 로 치환하면, 아래의 두 단계로 해  $x$ 를 구할 수 있습니다.

1. 전방 대입법 (Forward Substitution):  $Ly = b$ 를 풀어 중간 해  $y$ 를 구합니다.
2. 후방 대입법 (Backward Substitution):  $L^Tx = y$ 를 풀어 최종 해  $x$ 를 구합니다.

이 방식은 역행렬  $A^{-1}$ 을 직접 계산하는 것보다 수치적으로 훨씬 안정적이고 계산 비용이 저렴합니다.

# 1. Cholesky 분해 (Cholesky Decomposition)

## ✓ 1.1. 실습 데이터 준비 및 검증

일반적인 선형 시스템 문제에서는 행렬  $A$ 와 벡터  $b$ 가 주어지고, 미지의 해  $x$ 를 구하는 것이 목표입니다.

하지만 이 실습에서는 우리가 사용할 Cholesky 분해 방법이 올바르게 작동하는지 검증하는 것까지 목표로 합니다. 따라서 과정을 역으로 진행합니다.

1. 먼저, 우리가 찾고자 하는 정답  $x$ 를 임의로 정의합니다.
2. 그 다음, 이  $x$ 와 주어진  $A$ 를 사용하여  $Ax = b$ 를 만족하는 벡터  $b$ 를 계산합니다.

이렇게  $A$ 와  $b$ 가 준비되면,  $A$ 와  $b$ 가 주어졌을 때 미지의  $x$ 를 구하라는 형태의 선형 시스템 문제가 완성됩니다. 이어지는 단계에서는 Cholesky 분해를 이용해 이 문제의 해를 구하고, 그 결과가 우리가 미리 설정해 둔 정답  $x$ 와 일치하는지 비교하여 전체 풀이 과정의 정확성을 검증할 것입니다.

또한, 행렬  $A$ 가 Cholesky 분해의 필수 조건(대칭, 양의 정부호)을 만족하는지도 함께 검증합니다.

# 1. Cholesky 분해 (Cholesky Decomposition)

[3] # 실습: 아래 행렬 A의 값을 직접 바꿔보며, 검증 결과가 어떻게 변하는지 확인해보세요.

```
A_cholesky = np.array([
    [4., 2., 0.],
    [2., 5., 2.],
    [0., 2., 5.]
])
```

# 대칭 행렬 검증

```
is_symmetric = np.allclose(A_cholesky, A_cholesky.T)
```

# 양의 정부호 행렬 검증

```
if is_symmetric:
    eigenvalues = np.linalg.eigvalsh(A_cholesky)
    is_positive_definite = np.all(eigenvalues > 0)
```

# 실제 해 x를 정의하고 b를 계산

```
x_solution = np.array([1., 2., 3.])
b_cholesky = A_cholesky @ x_solution
```



행렬 A:

```
[[4. 2. 0.]
 [2. 5. 2.]
 [0. 2. 5.]]
```

-----  
A는 대칭 행렬인가? -> True

A는 양의 정부호 행렬인가? -> True  
-----

우리가 찾으려는 실제 해 x:

```
[1. 2. 3.]
```

계산된 벡터 b = Ax:

```
[ 8. 18. 19.]
```

# 1. Cholesky 분해 (Cholesky Decomposition)

## ✓ 1.2. Cholesky 분해 ( $A = LL^T$ )

이제 조건이 맞는 행렬  $A$ 를 하삼각행렬  $L$ 로 분해합니다.

```
[4] # scipy.linalg.cholesky는 기본적으로 하삼각행렬 L을 반환합니다.  
L = None  
if cholesky_possible:  
    L = scipy.linalg.cholesky(A_cholesky, lower=True)
```



Cholesky 분해 결과, 하삼각행렬  $L$ :

```
[[2. 0. 0.]  
 [1. 2. 0.]  
 [0. 1. 2.]]
```

분해 검증 ( $L @ L.T$ ):

```
[[4. 2. 0.]  
 [2. 5. 2.]  
 [0. 2. 5.]]
```

$A$ 와  $LL.T$ 가 일치하는가? True

# 1. Cholesky 분해 (Cholesky Decomposition)

## ✓ 1.3. 선형 시스템 풀이 (전방/후방 대입법)

분해된 L 행렬을 이용해, 선형 시스템을 두 단계로 나누어 풉니다.

1. 전방 대입법 ( $Ly = b$ ): 중간 해  $y$ 를 구합니다.
2. 후방 대입법 ( $L^T x = y$ ): 최종 해  $x$ 를 구합니다.

```
[5] if L is not None:
    # 1.  $Ly = b$  풀이 (전방 대입법)
    y = scipy.linalg.solve_triangular(L, b_cholesky, lower=True)
    print("1. 중간 해 y:\n", np.round(y, 2))

    # 2.  $L^T x = y$  풀이 (후방 대입법)
    x_cholesky = scipy.linalg.solve_triangular(L.T, y, lower=False)
    print("\n2. 최종 해 x:\n", np.round(x_cholesky, 2))
else:
    print("L이 생성되지 않아 풀이 과정을 건너뛰니다.")
```

⇄ 1. 중간 해  $y$ :  
[4. 7. 6.]

2. 최종 해  $x$ :  
[1. 2. 3.]



# 1. Cholesky 분해 (Cholesky Decomposition)

## ✓ 1.4. 최종 검증

Cholesky 분해를 통해 구한 해가 우리가 미리 정의했던 실제 해  $x$ 와 일치하는지, 그리고 `np.linalg.solve`를 이용해 직접 구한 해와도 일치하는지 확인하여 계산이 정확했는지 검증합니다.

```
[6] # 우리가 아는 실제 해와 비교
    print("Cholesky 해와 실제 해 x가 일치합니까?", np.allclose(x_cholesky, x_solution))

    # np.linalg.solve와 결과 비교
    x_direct = np.linalg.solve(A_cholesky, b_cholesky)
    print("np.linalg.solve 해와 실제 해 x가 일치합니까?", np.allclose(x_direct, x_solution))

    print("\nCholesky 해:\n", np.round(x_cholesky, 2))
    print("np.linalg.solve 해:\n", np.round(x_direct, 2))
    print("실제 해 x:\n", x_solution)
```



```
Cholesky 해와 실제 해 x가 일치합니까? True
np.linalg.solve 해와 실제 해 x가 일치합니까? True
```

```
Cholesky 해:
[1. 2. 3.]
np.linalg.solve 해:
[1. 2. 3.]
실제 해 x:
[1. 2. 3.]
```

## 2. 고유값 분해 (Eigendecomposition)

## 2. 고유값 분해 (Eigendecomposition)

### ✓ 2. 고유값 분해 (Eigendecomposition)

고유값 분해(Eigendecomposition)는 특정 조건을 만족하는 정방 행렬(square matrix) A를 세 행렬의 곱으로 분해하는 방법입니다.

$$A = PDP^{-1}$$

- A:  $n \times n$  크기의 정방 행렬(square matrix)입니다.
- P: A의 고유벡터(eigenvector)를 열(column)로 갖는 행렬입니다.
- D: A의 고유값(eigenvalue)을 대각 원소로 갖는 대각 행렬(diagonal matrix)입니다.
- $P^{-1}$ : P의 역행렬(inverse matrix)입니다.

이 분해는 행렬 A가  $n$ 개의 선형 독립(linearly independent)인 고유벡터를 가질 때, 즉 대각화(diagonalization)가 가능할 때 성립합니다.

$$A = \begin{bmatrix} \vdots & \vdots & & \vdots \\ v_1 & v_2 & \cdots & v_n \\ \vdots & \vdots & & \vdots \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix} \begin{bmatrix} \vdots & \vdots & & \vdots \\ w_1 & w_2 & \cdots & w_n \\ \vdots & \vdots & & \vdots \end{bmatrix}$$

위 식에서 첫 번째 행렬은 고유벡터(eigenvector) 행렬 P, 두 번째는 고유값(eigenvalue) 대각 행렬 D, 세 번째는 P의 역행렬(inverse matrix)  $P^{-1}$ 을 나타냅니다.

## 2. 고유값 분해 (Eigendecomposition)

기하학적 의미: 복잡한 변환을 간단한 단계로 분해하기

고유값 분해는 복잡한 행렬 변환  $A$ 를 세 단계의 간단한 변환으로 나누어 이해할 수 있게 해줍니다. 벡터  $x$ 에 행렬  $A$ 를 곱하는 변환  $Ax$ 는  $PDP^{-1}x$ 와 같으며, 다음과 같은 순서로 해석할 수 있습니다.

1. 좌표계 변환 ( $P^{-1}$  적용): 첫 단계는 벡터  $x$ 에 고유벡터 행렬의 역행렬  $P^{-1}$ 을 곱하는 것입니다. 이 연산은 벡터  $x$ 를 기존의 표준 좌표계에서 고유벡터들이 축을 이루는 새로운 좌표계로 변환합니다.
2. 크기 조절 ( $D$  적용): 다음으로, 변환된 좌표값에 고유값 대각 행렬  $D$ 를 곱합니다. 고유벡터 좌표계에서는 복잡한 변환  $A$ 가, 각 축의 성분을 해당 고유값  $\lambda_i$ 만큼 곱해주는 간단한 크기 조절(scaling) 연산으로 대체됩니다.
3. 좌표계 복원 ( $P$  적용): 마지막으로, 크기 조절이 완료된 벡터에 고유벡터 행렬  $P$ 를 곱합니다. 이 연산은 벡터를 다시 원래의 표준 좌표계로 되돌려 최종 변환 결과를 얻는 과정입니다.

## 2. 고유값 분해 (Eigendecomposition)

### 2.1. 실습 데이터 준비 및 분해 조건 확인

고유값 분해를 적용하기 전, 주어진 행렬이 분해 가능한지 확인합니다.  $n \times n$  행렬의 고유벡터들이  $n$ 차원 공간의 기저(basis)를 이룰 수 있는지, 즉 고유벡터 행렬  $P$ 가 역행렬을 갖는지 판별합니다.

$P$ 의 행렬식(determinant)이 0이 아니면,  $P$ 는 역행렬을 가지며 행렬  $A$ 는 고유값 분해가 가능합니다.

```
[24] # 실습에 사용할 2x2 정방 행렬(square matrix) 정의
# 행렬의 값을 바꾸어 분해 가능 여부를 테스트해볼 수 있습니다.
# 예: A = np.array([[1, 1], [0, 1]]) -> 분해 불가능
A = np.array([
    [3, 1],
    [1, 3]
])
print("행렬 A:\n", A)
print("-" * 30)

# 분해 가능성 확인
try:
    eigenvalues, P = np.linalg.eig(A)

    # P의 행렬식(determinant)이 0에 가까운지 확인하여 분해 가능성 판별
    determinant_P = np.linalg.det(P)
    is_diagonalizable = not np.isclose(determinant_P, 0)
```



행렬 A:

$\begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$

고유벡터 행렬 P의 행렬식: 1.00

행렬 A는 고유값 분해가 가능한가? -> True

## 2. 고유값 분해 (Eigendecomposition)

### 2.2. 고유값 분해 ( $A = PDP^{-1}$ )

분해 조건을 만족하는 행렬  $A$ 를  $P, D, P^{-1}$  행렬로 분해하고, 분해된 행렬들을 이용해 다시  $A$ 를 재구성해봅니다.

0s

```
[25] if is_diagonalizable:
    # D는 고유값(eigenvalue)을 대각 원소로 가지는 대각 행렬(diagonal matrix)
    D = np.diag(eigenvalues)

    # P의 역행렬(inverse matrix) 계산
    P_inv = np.linalg.inv(P)

    print("고유값  $\lambda$ :", eigenvalues)
    print("\n고유벡터 행렬 P:", np.round(P, 2))
    print("\n대각행렬 D:", np.round(D, 2))
    print("\nP의 역행렬  $P^{-1}$  :", np.round(P_inv, 2))

    # 분해 검증:  $A = PDP^{-1}$ 
    A_reconstructed = P @ D @ P_inv
    print("\n재구성된 행렬  $PDP^{-1}$  :", np.round(A_reconstructed, 2))
    print("\nA와  $PDP^{-1}$  이 일치하는가?", np.allclose(A, A_reconstructed))
else:
    print("행렬 A가 분해 조건을 만족하지 않아 분해를 진행하지 않습니다.")
```



고유값  $\lambda$ :  
[4. 2.]

고유벡터 행렬 P:  
[[ 0.71 -0.71]  
[ 0.71 0.71]]


대각행렬 D:  
[[4. 0.]  
[0. 2.]]

P의 역행렬  $P^{-1}$  :  
[[ 0.71 0.71]  
[-0.71 0.71]]

재구성된 행렬  $PDP^{-1}$  :  
[[3. 1.]  
[1. 3.]]

A와  $PDP^{-1}$  이 일치하는가? True


## 2. 고유값 분해 (Eigendecomposition)



위 그림은 행렬 변환 A가 공간에 어떤 영향을 미치는지 한눈에 보여줍니다.

- 파란색 점(단위 원)이 행렬 A에 의해 빨간색 점(타원)으로 변환됩니다.
- 대부분의 벡터는 변환 시 방향이 바뀌지만(검은색 화살표  $e_1, e_2$ 가 회색 화살표  $Ae_1, Ae_2$ 로 변하는 것을 보세요), 파란색 벡터만은 방향이 바뀌지 않습니다.
- 변환 후의 빨간색 화살표는 원래 고유벡터에서 크기만 고유값( $\lambda$ ) 배만큼 변한 것을 확인할 수 있습니다. ( $Av = \lambda v$ )
- 이 고유벡터들이 바로 선형 변환의 주축(principal axes)이 됩니다.

## 2. 고유값 분해 (Eigendecomposition)



### 고유값 분해의 시각적 이해

고유값 분해의 각 단계를 따라가 보면, 복잡해 보이는 변환  $A$ 가 사실은 세 가지 간단한 동작의 연속임을 알 수 있습니다. ( $A = PDP^{-1}$ )

- 1. Original Space & Eigenvectors:** 변환 전의 단위 원입니다. 여기에 행렬  $A$  변환의 핵심 방향인 고유벡터( $p_1, p_2$ )를 표시합니다. 이 두 벡터는 선형 변환 시 방향은 변하지 않고 크기만 변하는 특별한 축(axis) 역할을 합니다.
- 2. Align to Eigenbasis ( $P^{-1}$  적용):** 변환을 쉽게 파악하기 위해, 공간을 '회전'시켜 고유벡터  $p_1, p_2$ 가 표준 좌표축과 나란히 정렬되도록 만듭니다. 이로써 모든 변환이 축 방향으로 일어나도록 단순화됩니다. 이 '정렬' 역할을  $P^{-1}$  행렬이 수행합니다.
- 3. Scaling ( $D$  적용):** 정렬된 축을 따라 각 방향으로 고유값( $\lambda_1, \lambda_2$ )만큼 벡터들을 늘리거나 줄입니다. 대각행렬  $D$ 는 이처럼 간단한 스케일링 변환을 담당합니다.
- 4. Change Basis Back ( $P$  적용):** 크기 조절이 끝난 벡터들을 다시 원래의 고유벡터 방향으로 '역회전'시켜 본래의 좌표계로 되돌려 놓습니다. 이 역할을  $P$  행렬이 수행합니다. 그 결과는 행렬  $A$ 를 직접 적용한 변환 결과와 정확히 일치합니다.

결론적으로, 고유값 분해는 복잡한 선형 변환을 가장 다루기 쉬운 방향(고유벡터)이 좌표축과 일치하도록 공간을 정렬하고, 그곳에서 간단한 크기 조절(scaling)을 한 뒤, 다시 원래의 방향으로 되돌려 놓는 과정으로 해석할 수 있습니다.



### 3. 특이값 분해 (Singular Value Decomposition, SVD)

### 3. 특이값 분해 (Singular Value Decomposition, SVD)

#### 3. 특이값 분해 (Singular Value Decomposition, SVD)

특이값 분해(SVD)는 임의의  $m \times n$  행렬  $A$ 를 세 행렬의 곱으로 분해하는 방법입니다. 고유값 분해가 정방 행렬(square matrix)에만 적용 가능한 것과 달리, SVD는 모든 행렬에 적용할 수 있어 활용도가 매우 높습니다.

$$A = U\Sigma V^T$$

- $A$ :  $m \times n$  크기의 행렬입니다.
- $U$ :  $m \times m$  크기의 직교 행렬(orthogonal matrix)입니다. 열벡터는 좌측 특이벡터(left-singular vectors)라고 합니다. ( $UU^T = I$ )
- ( $\Sigma$ ):  $m \times n$  크기의 대각 행렬(diagonal matrix)입니다. 대각 원소는 특이값(singular values)이며, 0이 아닌 값들은 행렬  $A$ 의 양의 정부호(positive definite) 행렬인  $A^T A$ 의 고유값의 제곱근과 같습니다.
- $V^T$ :  $n \times n$  크기의 직교 행렬(orthogonal matrix)  $V$ 의 전치 행렬입니다.  $V$ 의 열벡터는 우측 특이벡터(right-singular vectors)라고 합니다. ( $VV^T = I$ )

$$A = \begin{bmatrix} \vdots & \vdots & & \vdots \\ u_1 & u_2 & \cdots & u_m \\ \vdots & \vdots & & \vdots \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix} \begin{bmatrix} \cdots & v_1 & \cdots \\ \cdots & v_2 & \cdots \\ \vdots & & \\ \cdots & v_n & \cdots \end{bmatrix}$$

### 3. 특이값 분해 (Singular Value Decomposition, SVD)

기하학적 의미: 복잡한 변환을 회전, 크기 조절, 다시 회전으로 분해하기

SVD는 복잡한 행렬 변환  $A$ 를 세 단계의 간단한 변환으로 나누어 이해할 수 있게 해줍니다. 벡터  $x$ 에 행렬  $A$ 를 곱하는 변환  $Ax$ 는  $U\Sigma V^T x$ 와 같으며, 다음과 같은 순서로 해석할 수 있습니다.

1. 좌표계 회전 ( $V^T$  적용): 첫 단계는 벡터  $x$ 에  $V^T$ 를 곱하는 것입니다. 이 연산은 입력 공간( $\mathbb{R}^n$ )의 표준 기저를 우측 특이벡터( $v_i$ )를 축으로 하는 새로운 좌표계로 회전시킵니다.
2. 크기 조절 및 차원 변경 ( $\Sigma$  적용): 다음으로, 변환된 좌표값에 대각 행렬  $\Sigma$ 를 곱합니다. 이 과정에서 각 축의 성분을 해당 특이값  $\sigma_i$ 만큼 곱해주는 크기 조절(scaling)이 일어나고, 동시에 차원이  $m$ 으로 변경됩니다. (예:  $\mathbb{R}^n \rightarrow \mathbb{R}^m$ )
3. 좌표계 회전 ( $U$  적용): 마지막으로, 크기 조절이 완료된 벡터에  $U$ 를 곱합니다. 이 연산은 출력 공간( $\mathbb{R}^m$ )에서 벡터를 좌측 특이벡터( $u_i$ )를 축으로 하는 좌표계로 다시 한번 회전시켜 최종 변환 결과를 얻습니다.

# 3. 특이값 분해 (Singular Value Decomposition, SVD)

## 3.1. SVD 분해 및 결과 확인

SVD는 모든 행렬에 적용 가능합니다. 여기서는  $R^2$  공간의 벡터를  $R^3$  공간으로 변환하는 3x2 행렬을 사용해 SVD를 실행하고, 분해된 행렬들을 확인하며 결과를 검증합니다.

```
[28] # 실습에 사용할 3x2 행렬(matrix) 정의
```

```
A = np.array([
    [1, 2],
    [2, 1],
    [1, 1]
])
```

```
# SVD 수행
```

```
# full_matrices=True로 하면 U는 m x m, Vh는 n x n 정방행렬이 반환됩니다.
```

```
# U: (m, m), s: (k,), Vh: (n, n) where k = min(m, n)
```

```
U, s, Vh = np.linalg.svd(A, full_matrices=True)
```

```
# Vh의 V는 Vh.T로 얻을 수 있음.
```

```
V = Vh.T
```

```
# s는 특이값(singular values)의 1차원 배열이므로, m x n 크기의 대각 행렬 Sigma로 재구성해야 함.
```

```
Sigma = np.zeros(A.shape)
```

```
k = min(A.shape)
```

```
Sigma[:k, :k] = np.diag(s)
```

```
# 분해 검증: A = UΣVT
```

```
A_reconstructed = U @ Sigma @ Vh
```

↻ 행렬 A:

```
[[1 2]
 [2 1]
 [1 1]]
```

U 행렬 (좌측 특이벡터):

```
[[ -0.64  0.71 -0.3 ]
 [ -0.64 -0.71 -0.3 ]
 [ -0.43 -0.   0.9 ]]
```

대각행렬 Σ (특이값):

```
[[3.32 0. ]
 [0.   1. ]
 [0.   0. ]]
```

V 전치 행렬 V<sup>T</sup> (우측 특이벡터의 전치):


```
[[ -0.71 -0.71]
 [ -0.71  0.71]]
```

재구성된 행렬 UΣV<sup>T</sup>:

```
[[1. 2.]
 [2. 1.]
 [1. 1.]]
```

A와 UΣV<sup>T</sup>이 일치하는가? True

### 3. 특이값 분해 (Singular Value Decomposition, SVD)



위 그림은 행렬 변환 A가 2차원 공간을 3차원 공간으로 어떻게 변환하는지 보여줍니다.

- 파란색 점( $z=0$  평면 위의 단위 원)이 행렬 A에 의해 3차원 공간의 빨간색 점(타원)으로 변환됩니다.
- 입력 공간( $R^2$ )의 서로 직교하는 두 우측 특이벡터( $v_1, v_2$ )는 변환 후에도 여전히 서로 직교하는 벡터( $Av_1, Av_2$ )가 됩니다. 이 벡터들은 출력 공간( $R^3$ )에 있는 타원의 장축과 단축을 형성합니다.
- 변환된 벡터  $Av_1, Av_2$ 의 길이는 각각 특이값  $\sigma_1, \sigma_2$  배만큼 조절되며, 방향은 좌측 특이벡터  $u_1, u_2$ 의 방향과 일치합니다. ( $Av_i = \sigma_i u_i$ )
- 즉, SVD는 입력 공간의 직교 기저( $V$ )를 출력 공간의 직교 기저( $U$ )로 매핑하는 변환으로 이해할 수 있습니다.

## 4. 주성분 분석 (Principal Component Analysis, PCA)

## 4. 주성분 분석 (Principal Component Analysis, PCA)

### ✓ 4. 주성분 분석 (Principal Component Analysis, PCA)

주성분 분석(PCA)은 대표적인 차원 축소(Dimensionality Reduction) 기법입니다. 데이터에 내재된 정보 손실을 최소화하면서 고차원 데이터를 저차원 공간으로 선형 변환하는 방법으로, 데이터의 분산(variance)이 가장 큰 방향을 새로운 좌표축, 즉 주성분(Principal Component)으로 설정합니다.

PCA의 수학적 핵심은 데이터의 공분산 행렬(Covariance Matrix)에 대한 고유값 분해(Eigendecomposition)입니다. 각 특징(열)의 평균을 0으로 중심화한 데이터 행렬  $X$ (샘플 수  $\times$  특징 수)가 주어졌을 때, 공분산 행렬  $C$ 는 다음과 같이 계산됩니다.

$$C = \frac{1}{n-1} X^T X \quad (\text{단, } X \text{는 평균이 } 0 \text{으로 중심화된 데이터})$$

이 공분산 행렬  $C$ 를 고유값 분해하면 다음과 같습니다.

$$C = W \Lambda W^T$$

- $W$ : 공분산 행렬  $C$ 의 고유벡터(eigenvector)들을 열(column)으로 갖는 직교 행렬(orthogonal matrix)입니다. 이 고유벡터들이 데이터의 분산이 가장 큰 방향을 나타내는 새로운 축, 즉 주성분(Principal Components)이 됩니다.
- $\Lambda$ :  $C$ 의 고유값(eigenvalue)들을 대각 원소로 갖는 대각 행렬(diagonal matrix)입니다. 각 고유값은 해당 고유벡터(주성분) 방향으로 데이터가 갖는 분산의 크기를 의미하며, 이 값이 클수록 해당 주성분이 더 많은 정보를 설명함을 뜻합니다.

## 4. 주성분 분석 (Principal Component Analysis, PCA)

### 기하학적 의미: 데이터의 새로운 주축 찾기

PCA는 복잡하게 얽혀 있는 데이터를 가장 잘 설명할 수 있는 새로운 좌표계를 찾는 과정으로 해석할 수 있습니다. 주성분은 고유값이 큰 순서대로 정렬되며, 첫 번째 주성분이 데이터의 분산을 가장 많이 설명합니다.

1. 첫 번째 주성분(PC1) 탐색: 데이터를 특정 방향(1차원 직선)으로 정사영(projection)했을 때, 그 분산이 가장 커지는 방향을 찾습니다. 이 방향 벡터가 바로 데이터를 가장 잘 대표하는 첫 번째 주성분(PC1) 축이 됩니다.
2. 두 번째 주성분(PC2) 탐색: 첫 번째 주성분(PC1)에 직교(orthogonal)하는 방향들 중에서, 데이터를 정사영했을 때 분산이 가장 커지는 다음 방향을 찾습니다. 이 방향이 두 번째 주성분(PC2)이 됩니다.
3. 반복 및 좌표계 생성: 이 과정을 반복하면, 데이터의 원래 차원 수만큼 서로 직교하는 주성분 축들을 얻을 수 있습니다. 이 주성분들은 데이터를 설명하는 새로운 좌표계의 기저(basis)를 이룹니다.
4. 차원 축소: 각 주성분은 해당 축 방향의 분산 크기를 나타내는 고유값을 가집니다. 고유값이 큰 상위  $k$ 개의 주성분(데이터의 분산을 많이 설명하는 축)만 선택하고, 원본 데이터를 이  $k$ 개의 축으로 이루어진 새로운 공간에 정사영하면, 데이터의 정보 손실을 최소화하며 차원을 효과적으로 축소할 수 있습니다.



## 4. 주성분 분석 (Principal Component Analysis, PCA)

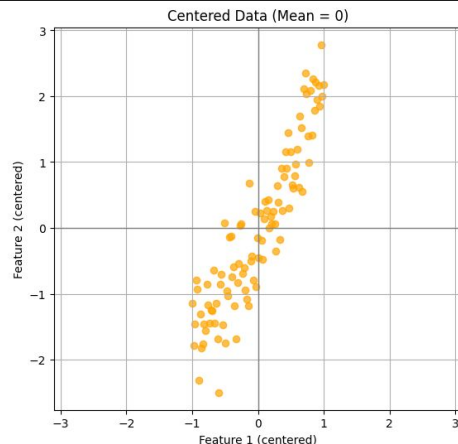

### 4.1. 데이터 생성 및 중심화

두 변수 간에 강한 상관관계를 갖는 2차원 데이터를 생성합니다. PCA는 분산을 기반으로 하므로, 분석에 앞서 각 변수의 평균을 0으로 맞추는 데이터 중심화(Centering) 전처리를 필수로 수행합니다.

✓  
0s

```
[30] # 2D 예제 데이터 생성
      num_samples = 100
      x_pca_2d = np.linspace(3, 5, num_samples)
      y_pca_2d = 2 * x_pca_2d - 4 + np.random.normal(0, 0.5, num_samples)
      data_2d = np.array([x_pca_2d, y_pca_2d]).T
```

```
# 데이터 전처리: 평균 중심화 (모든 데이터 포인트에서 평균 뺀)
mean_vec = np.mean(data_2d, axis=0)
centered_data = data_2d - mean_vec
```



## 4. 주성분 분석 (Principal Component Analysis, PCA)

### 4.2. 주성분 계산 (공분산 행렬의 고유값 분해)


중심화된 데이터의 공분산 행렬을 계산하고, 이를 고유값 분해하여 주성분(고유벡터)과 그 중요도(고유값)를 찾습니다. 고유값이 가장 큰 고유벡터가 제1 주성분(PC1)이 됩니다.

```
[31] # 공분산 행렬 계산
# np.cov는 (특징 수, 샘플 수) 형태의 입력을 기대하므로, (샘플 수, 특징 수)
cov_matrix = np.cov(centered_data.T)

# 공분산 행렬의 고유값 분해
# 대칭행렬이므로 eig를 사용하면 더 효율적이고 안정적입니다.
eigenvalues_pca, eigenvectors_pca = np.linalg.eigh(cov_matrix)

# 고유값이 큰 순서대로 고유값과 고유벡터를 정렬합니다.
sort_indices = np.argsort(eigenvalues_pca)[::-1]
eigenvalues_pca = eigenvalues_pca[sort_indices]
eigenvectors_pca = eigenvectors_pca[:, sort_indices]

# 제1 주성분(PC1)은 가장 큰 고유값에 해당하는 고유벡터입니다.
pc1 = eigenvectors_pca[:, 0]
pc2 = eigenvectors_pca[:, 1]
```




## 4. 주성분 분석 (Principal Component Analysis, PCA)

### 4.3. 차원 축소 및 데이터 재구성

2차원 데이터를 PC1 축 하나로 사영(projection)하여 1차원으로 축소하고, 다시 2차원으로 복원해봅니다. 이 과정은 PCA가 정보 손실을 감수하고 데이터의 가장 중요한 특징으로 원본을 근사하는 과정을 명확히 보여줍니다. 재구성된 데이터는 PC1 직선 위에 위치하게 됩니다.

```
[32] # 차원 축소: 중심화된 데이터를 PC1 벡터에 사영하여 2D -> 1D로 변환
      projected_data_1d = centered_data @ pc1

      # 데이터 재구성: 1D 데이터를 다시 2D 공간으로 복원
      # (사영된 1D 데이터)와 (PC1 벡터)의 외적(outer product)을 이용합니다.
      reconstructed_centered_data = projected_data_1d[:, np.newaxis] @ pc1[np.newaxis, :]
      # 원본 데이터 공간으로 이동 (데이터 중심화 시 뺀 평균을 다시 더해줌)
      reconstructed_data = reconstructed_centered_data + mean_vec
```



## 4. 주성분 분석 (Principal Component Analysis, PCA)

### 4.4. MNIST 데이터 준비 및 분산 설명량 확인

784차원의 고차원 MNIST 이미지 데이터에 PCA를 적용합니다. 각 주성분이 전체 데이터 분산의 몇 %를 설명하는지 시각화하여, 몇 개의 주성분이 데이터의 정보를 효과적으로 압축하는지 확인합니다.

- 스크리 도표(Scree Plot): 각 주성분(고유값)의 상대적 중요도를 시각적으로 보여줍니다.
- 누적 분산 설명량 그래프: k개의 주성분을 사용했을 때, 원본 분산의 몇 %를 보존할 수 있는지 보여줍니다.

```
[33] # 실습: 분석하고 싶은 숫자들을 리스트에 포함시켜 보세요. 예: [3, 8], [0, 1, 7], list(range(10))
selected_digits = [0, 1, 8]

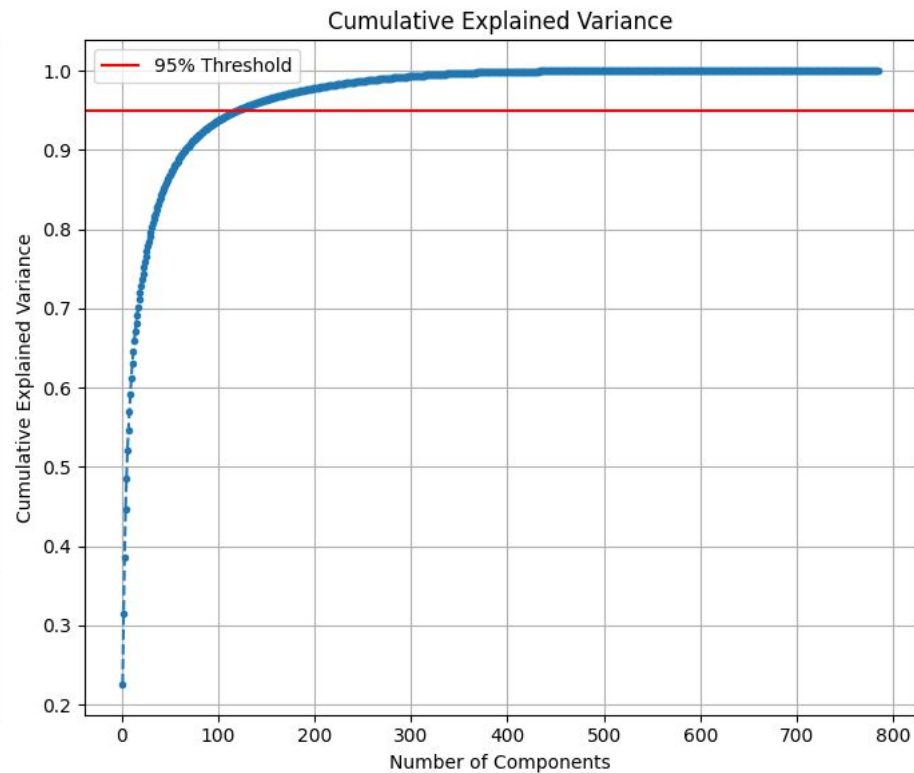

# 선택된 숫자에 해당하는 데이터만 필터링
if X_mnist_data is not None:
    filter_mask = np.isin(y_mnist_data, selected_digits)
    X_mnist = X_mnist_data[filter_mask]
    y_mnist = y_mnist_data[filter_mask]
    print(f"선택된 숫자: {selected_digits}, 데이터 크기: {X_mnist.shape}")

# 데이터 중심화
X_centered_mnist = X_mnist - np.mean(X_mnist, axis=0)

# 공분산 행렬 계산 및 고유값 분해
cov_matrix_mnist = np.cov(X_centered_mnist.T)
eigenvalues_mnist, eigenvectors_mnist = np.linalg.eigh(cov_matrix_mnist)
sort_indices_mnist = np.argsort(eigenvalues_mnist)[::-1]
eigenvalues_mnist = eigenvalues_mnist[sort_indices_mnist]
eigenvectors_mnist = eigenvectors_mnist[:, sort_indices_mnist]

# 분산 설명량 계산
explained_variance_ratio = eigenvalues_mnist / np.sum(eigenvalues_mnist)
cumulative_explained_variance = np.cumsum(explained_variance_ratio)
```

## 4. 주성분 분석 (Principal Component Analysis, PCA)



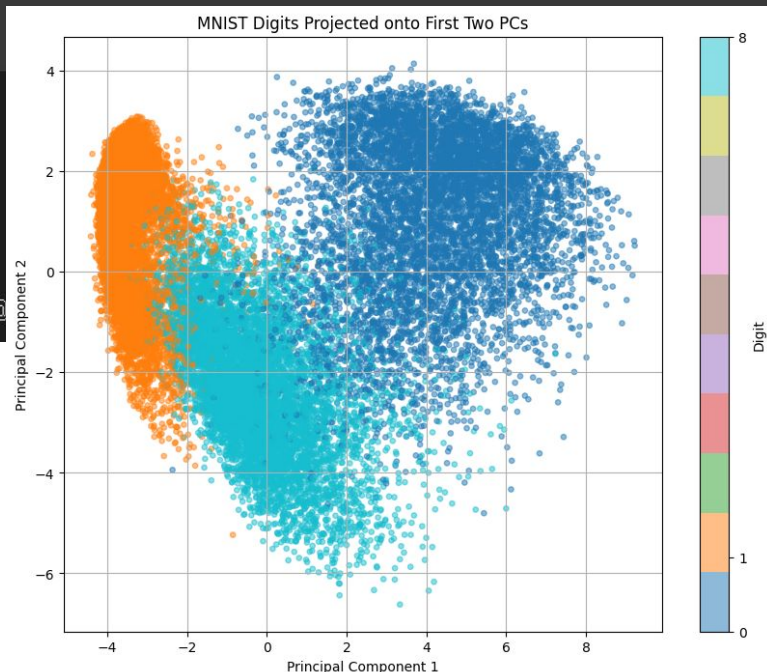
## 4. 주성분 분석 (Principal Component Analysis, PCA)

### 4.5. 저차원 시각화 및 이미지 재구성

784차원의 이미지 데이터를 가장 중요한 두 개의 주성분(PC1, PC2)만 사용하여 2차원으로 축소하고, 그 결과를 산점도로 시각화하여 데이터의 분포를 확인합니다. 또한, 사용하는 주성분의 개수(k)를 늘려가며 원본 이미지를 재구성하여, 적은 수의 주성분만으로도 원본 이미지의 핵심 특징이 복원되는 것을 관찰합니다.

✓  
10s

```
[34] if X_mnist_data is not None:
      # 2차원으로 사영 및 시각화
      # 가장 중요한 두 주성분(PC1, PC2)을 선택합니다.
      pc1_mnist = eigenvectors_mnist[:, 0]
      pc2_mnist = eigenvectors_mnist[:, 1]
      # 중심화된 데이터를 PC1, PC2에 사영합니다.
      projected_mnist = np.c_[X_centered_mnist @ pc1_mnist, X_centered_mnist @
```



## 4. 주성분 분석 (Principal Component Analysis, PCA)

```
# 각 숫자 클래스에서 첫 번째 샘플을 선택합니다.
sample_indices = [np.where(y_mnist == digit)[0][0] for digit in selected_digits if np.any(y_mnist == digit)]

# 실습: 이미지를 재구성할 때 사용할 주성분 개수(k)를 바꿔보세요.
k_values = [1, 10, 50, n_components_95, 300, 784]
num_k = len(k_values)
num_samples_to_show = len(sample_indices)

fig, axes = plt.subplots(num_samples_to_show, num_k + 1, figsize=(num_k * 2.2, num_samples_to_show * 2.2))
if num_samples_to_show == 1: axes = axes.reshape(1, -1)

mean_image = np.mean(X_mnist, axis=0)
```



## 4. 주성분 분석 (Principal Component Analysis, PCA)

